








Сопоставление изображений и локальные особенности



Антон Конушин

<http://courses.graphicon.ru/main/vision>


Many slides adopted from Svetlana Lazebnik, Steve Seitz and Alexey Efros



Задача сопоставления изображений



Построение панорам




Распознавание
экземпляров
объектов

«Image alignment», «Image matching»



Выравнивание изображений



Есть два изображения одного и того же объекта.


Как нам совместить изображения автоматически?

- Найдём такое преобразование (совмещение изображений), при котором изображения больше всего совпадут
 - Прямое согласование (direct alignment)
- Что нам нужно определить:
 - Какое преобразование будем использовать?
 - Как оценить совпадение (похожесть изображений)?



Геометрические преобразования


- Параллельный перенос




- Подобие (перенос, масштаб, поворот)



- Аффинное



- Проективное (гомография)





Геометрические преобразования

- Параллельный перенос

$$\begin{bmatrix} x'_i \\ y'_i \end{bmatrix} = \begin{bmatrix} x_i \\ y_i \end{bmatrix} + \begin{bmatrix} t_1 \\ t_2 \end{bmatrix}$$

- Евклидово преобразование
(M – ортогональная матрица)

$$\begin{bmatrix} x'_i \\ y'_i \end{bmatrix} = \begin{bmatrix} m_1 & m_2 \\ m_3 & m_4 \end{bmatrix} \begin{bmatrix} x_i \\ y_i \end{bmatrix} + \begin{bmatrix} t_1 \\ t_2 \end{bmatrix}$$


- Аффинное преобразование

$$\begin{bmatrix} x'_i \\ y'_i \end{bmatrix} = \begin{bmatrix} m_1 & m_2 \\ m_3 & m_4 \end{bmatrix} \begin{bmatrix} x_i \\ y_i \end{bmatrix} + \begin{bmatrix} t_1 \\ t_2 \end{bmatrix}$$



Гомография

- Перспективное преобразование плоскости
- Переводит четырехугольник в другой произвольный четырехугольник





Гомография

- Преобразование между 2мя разными видами одной и той же плоскости



- Преобразование между видами с повернутой камеры (центр проекции общий)





Однородные координаты

- Однородные координаты

$$(x, y) \Rightarrow \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}$$

Перевод в однородные
координаты

$$\begin{bmatrix} x \\ y \\ w \end{bmatrix} \Rightarrow (x/w, y/w)$$

Перевод из однородных
координат

Удобнее представлять себе так:

$$\begin{bmatrix} wx & wy & w \end{bmatrix}^T \cong \begin{bmatrix} x & y & 1 \end{bmatrix}^T \cong \begin{bmatrix} x & y \end{bmatrix}^T$$


Подробнее будет в лекциях про геометрические свойства камер!



Уравнение гомографии

$$\lambda \begin{bmatrix} x'_i \\ y'_i \\ 1 \end{bmatrix} = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ h_{21} & h_{22} & h_{23} \\ h_{31} & h_{32} & h_{33} \end{bmatrix} \begin{bmatrix} x_i \\ y_i \\ 1 \end{bmatrix} \quad \lambda x' = Hx$$

Гомография – линейное преобразование в однородных координатах





Сравнение изображений

Попиксельное сравнение изображений:

$$\sum_X \sum_Y |I_1(X, Y) - I_2(X, Y)|$$

L1 метрика (SAD - Sum of absolute differences)

$$\sum_X \sum_Y (I_1(X, Y) - I_2(X, Y))^2$$

L2 метрика (SSD - Sum of squared differences)

$$\sum_X \sum_Y I_1(X, Y) I_2(X, Y)$$

Кросс-корреляция (CC - Cross-correlation)

- SAD, SSD – минимизируются (0 – точное совпадение)
- CC – максимизируется (1 – точное совпадение)



Алгоритм

Простейший подход – «грубой силы» (brute force)

- Выберем модель преобразования, определим набор параметров, его описывающих
- Выберем функцию сопоставления изображений
 - SSD, Нормализованная корреляция, и т.д.
- Переберём всевозможные значения параметров в разумных пределах:

Пример – параллельный перенос:

```
for tx=x0:step:x1,  
  for ty=y0:step:y1,  
    compare image1(x,y) to image2(x+tx,y+ty)  
  end;  
end;
```

Необходимо заранее выбрать x_0, x_1 и $step$

Что мы ещё не учли?




Задача оптимизации параметров

- Фактически, сопоставление изображений, это задача поиска минимума функции сравнения изображений
- Мы рассмотрели вариант полного перебора параметров с некоторым шагом
 - Grid search
- Можем воспользоваться каким-нибудь другим методом оптимизации, например, градиентным спуском
 - Хорошо работает только в случае точного начального приближения
 - Ошибка менее 2х пикселей
- Можно улучшить с помощью многомасштабного подхода



Пирамиды изображений

Idea: Represent $N \times N$ image as a “pyramid” of $1 \times 1, 2 \times 2, 4 \times 4, \dots, 2^k \times 2^k$ images (assuming $N = 2^k$)




- Известна как Пирамида Гауссиан
- В компьютерной графике – “mip map” [Williams, 1983]


P. Burt and E. Adelson, “The Laplacian pyramid as a compact image code,” *IEEE Trans. Commun.*, vol. 31, no. 4, pp. 532–540, 1983.



Построение пирамиды



- Повторяем до достижения минимального разрешения
 - Сглаживаем с помощью фильтра Гаусса текущее изображение
 - Сэмплируем – берём каждый k -ый пиксель (обычно, каждый 2ой)



512

256

128

64

32

16

8

На высшем
уровне
полоса в
пиксель —
волос, на
среднем —
полоска, на
нижнем -
нос



Figure from David Forsyth





Многомасштабное сопоставление

- Идея метода
 - Строим гауссовы пирамиды для каждого из 2х изображений
 - Ищем преобразование на самом низком разрешении
 - Можно использовать полный перебор
 - Используем как начальное приближение для сопоставления на следующем уровне
 - Для уточнения можем использовать градиентный спуск
- Проблемы
 - Если на нижнем уровне ошиблись, тогда на следующих не можем исправить ошибку
 - Всё равно медленно
 - Проблема устойчивости




Перекрывание объекта



- Как быть, если объект («дом») частично перекрыт другими объектами («ёлками»)
- Положение «ёлок» относительно дома разное на разных ракурсах
- Прямое попиксельное сопоставление изображений может не дать хорошего результата



Локальные особенности



- Найти хорошо различимые точки на изображениях
 - «особенности» (features)
 - «локальный особые точки» (local feature points)
 - «характеристические точки» (characteristic points)
- Сопоставить точки (feature matching)
 - Определить, какой точке на одном изображении соответствуют какая точка на втором изображении
- Найти такое преобразование, которое совмещает найденные точки



Применение

Microsoft
Research



Сопоставление изображений и трёхмерная
реконструкция



Применение



Классификация изображений и выделение объектов



Применение




Поиск изображений по содержанию в базе изображений



Локальные особенности



Пример особой
точки




Пример точки, не
являющейся особой

- Локальная (особая) точка p изображения I
 - это точка с характерной (особой) окрестностью, т.е. отличающаяся от всех других точек в некоторой окрестности p



Требования к особенностям




- Повторимость (Repeatability)
 - Особенность находится в том же месте сцены не смотря на изменения точки обзора и освещения
- Локальность (Locality)
 - Особенность занимает маленькую область изображения, поэтому работа с ней нечувствительна к перекрытиям
- Значимость (Saliency)
 - Каждая особенность имеет уникальное (distinctive) описание
- Компактность и эффективность
 - Количество особенностей существенно меньше числа пикселей изображения




Локальные особенности


Проведём эксперимент, будем рассматривать разные точки на изображении и проверять, являются ли они локальными особенностями



монотонный регион:
в любом направлении
изменений нет




«край»:
вдоль края
изменений нет



«уголок»:
изменения при
перемещении
в любую сторону



Детектор Харриса



- Наиболее популярный детектор локальных особенностей точек – детектор Харриса (Harris)
- Главное свойство угла
 - в области вокруг угла у градиента изображения два доминирующих направления
- Уголки хорошо повторимы и различимы

C.Harris and M.Stephens. ["A Combined Corner and Edge Detector."](#)
Proceedings of the 4th Alvey Vision Conference: pages 147—151, 1988



Математические детали

Изменение окрестности точки (x, y) при сдвиге $[u, v]$:


$$E(u, v) = \sum_{x, y} w(x, y) [I(x + u, y + v) - I(x, y)]^2$$

Функция
окна

Сдвиг
яркости


Яркость

Функция окна $w(x, y) =$



1 в окне, 0 вне

или



Гауссиана



Математические детали

Изменение окрестности точки при сдвиге $[u, v]$:

$$E(u, v) = \sum_{x, y} w(x, y) [I(x + u, y + v) - I(x, y)]^2$$

Разложение в ряд Тейлора 2го порядка $I(x, y)$ вокруг (x, y)
(билинейная интерполяция при маленьких сдвигах)

$$[I(x + u, y + v) - I(x, y)]^2 \cong [I(x, y) + I_x u + I_y v - I(x, y)]^2$$

$$= [I_x u + I_y v]^2 = I_x^2 u^2 + 2 I_x I_y uv + I_y^2 v^2$$

$$= (u, v) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} (u, v)^T$$



Математические детали

Итого изменение окрестности можно свести к:

$$E(u, v) \approx [u \ v] M \begin{bmatrix} u \\ v \end{bmatrix}$$

где M – матрица 2×2 вычисленная по частным производным:


$$M = \sum_{x,y} w(x, y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$

$$M = \begin{bmatrix} \sum I_x I_x & \sum I_x I_y \\ \sum I_x I_y & \sum I_y I_y \end{bmatrix} = \sum \begin{bmatrix} I_x \\ I_y \end{bmatrix} [I_x \ I_y] = \sum \nabla I (\nabla I)^T$$



Интерпретация матрицы моментов

Рассмотрим случай, когда градиенты выровнены по осям (вертикальные или горизонтальные)



$$M = \sum \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix}$$

Если одно из λ близко к 0, тогда это не угол, и нужно искать другие точки



Общий случай

M – симметричная, поэтому её можно привести к диагональному виду:

$$M = R^{-1}DR = R^{-1} \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} R$$


R – ортогональная матрица из собственных векторов M , D – диагональная из собственных значений M

Матрицу M можно визуализировать в виде эллипса, у которого длины осей определены собственными значениями, а ориентация определена матрицей R

Уравнение эллипса:

$$\begin{bmatrix} u & v \end{bmatrix} M \begin{bmatrix} u \\ v \end{bmatrix} = \text{const}$$


Направление
наибыстрого
изменения



Направление
наимедленного
изменения



Пример



Визуализация матриц вторых моментов (Гессианов)



Детекторы углов


Классификация точек
изображения по
собственным значениям
матрицы производных M

$$E(u, v) = (u, v)M(u, v)^T$$

$$M = R^{-1} \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} R$$

λ_1 и λ_2 малы;
 E не меняется по
всем направлениям

λ_2



λ_1



Детекторы углов

- Мера отклика угла по Харрису:

$$R = \det M - k (\text{trace } M)^2$$


$$\det M = \lambda_1 \lambda_2$$

$$\text{trace } M = \lambda_1 + \lambda_2$$

$$(k = 0.04-0.06)$$

- Мера по Фёрстнеру (Forstner):

$$R = \det M / \text{trace } M$$





Алгоритм детектора Харриса

1. Вычислить градиент изображения в каждом пикселе
 - С использованием гауссова сглаживания
2. Вычислить матрицу вторых моментов M по окну вокруг каждого пикселя
3. Вычислить отклик угла R
4. Отсечение по порогу R
5. Найти локальные максимумы функции отклика (non-maximum suppression) по окрестности заданного радиуса
6. Выбор N самых сильных локальных максимумов




Демонстрация по шагам





Демонстрация по шагам


Вычисление отклика угла R





Демонстрация по шагам


Найдём точки с большим откликом $R > \text{порог}$





Демонстрация по шагам

Оставим только точки локальных максимумов R






Демонстрация по шагам






Результат работы детектора



детектор Фёрстнера

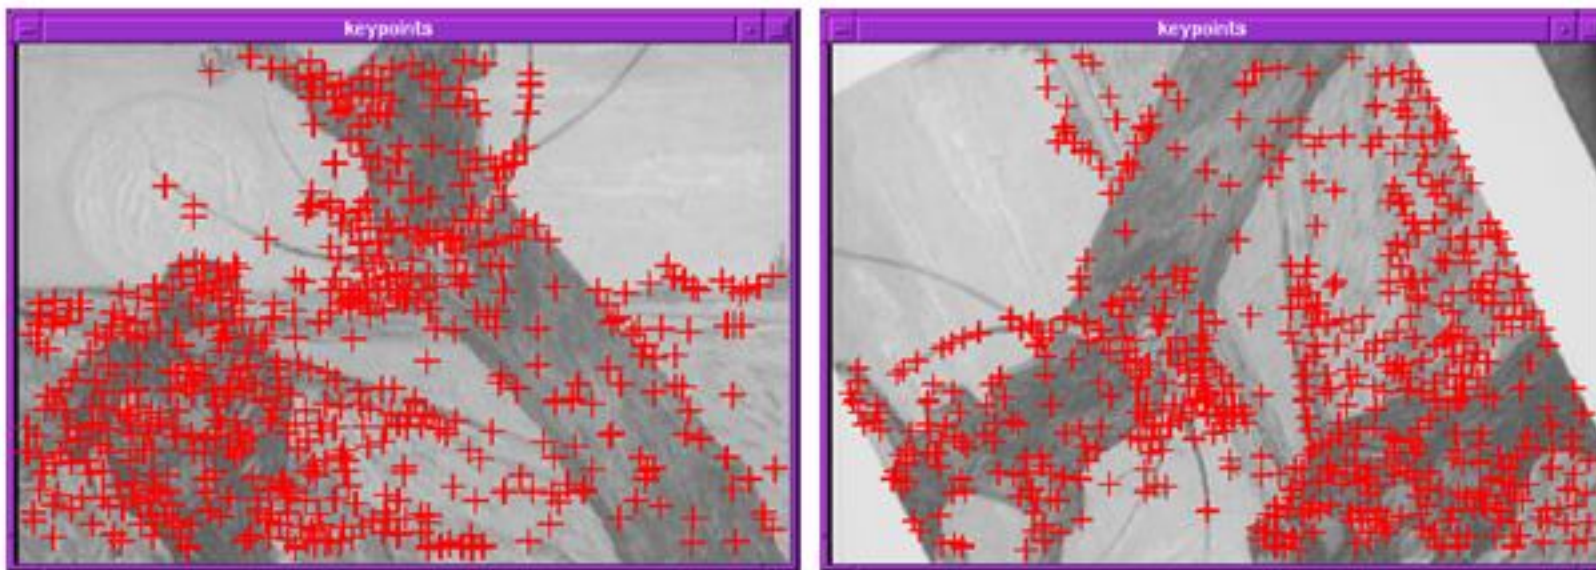


детектор Харриса



Инвариантность

- Хорошо бы чтобы особенности находились в одной и той же точки сцены, на изображениях с разных ракурсов и в разных условиях освещения
- Если применить геометрическое преобразование к изображению, то алгоритм должен найти тот же самый набор точек







Модели преобразования

Геометрические


- Поворот



- Масштаб




- Аффинное



подходит для упрощенных моделей камер
(ортографической проекции, локально-плоских объектов)

Фотометрические

- Аффинное изменение яркости ($I \rightarrow a I + b$)






Детекторы Харриса

■ Частичная инвариантность к изменению освещенности

✓ Используются только производные
=> инвариантность к сдвигу $I \rightarrow I + b$


✓ Масштабирование: $I \rightarrow a I$





Детектор Харриса

Инвариантность к вращению изображения:



$$M = R^{-1} \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} R$$


Эллипс вращается, но его форма (собственные значения) остаются неизменными

Отклик угла R инвариантен относительно вращению изображения




Масштабирование?

- Угол или нет? - Зависит от масштаба изображения!



Все эти точки будут
помечены как **края**




Угол !




Инвариантность к масштабированию

- Цель: определять размер окрестности особой точки в масштабированных версиях одного и того же изображения
- Требуется метод выбора размера характеристической окрестности






Блобы



«Капля», «Blob» - вначале для особенностей такого типа была разработана теория выбора характерного размера




Поиск краев






Второй проход

f




Край

$\frac{d^2}{dx^2} g$



Вторая
производная
Гауссианы
(Лапласиан)

$f * \frac{d^2}{dx^2} g$

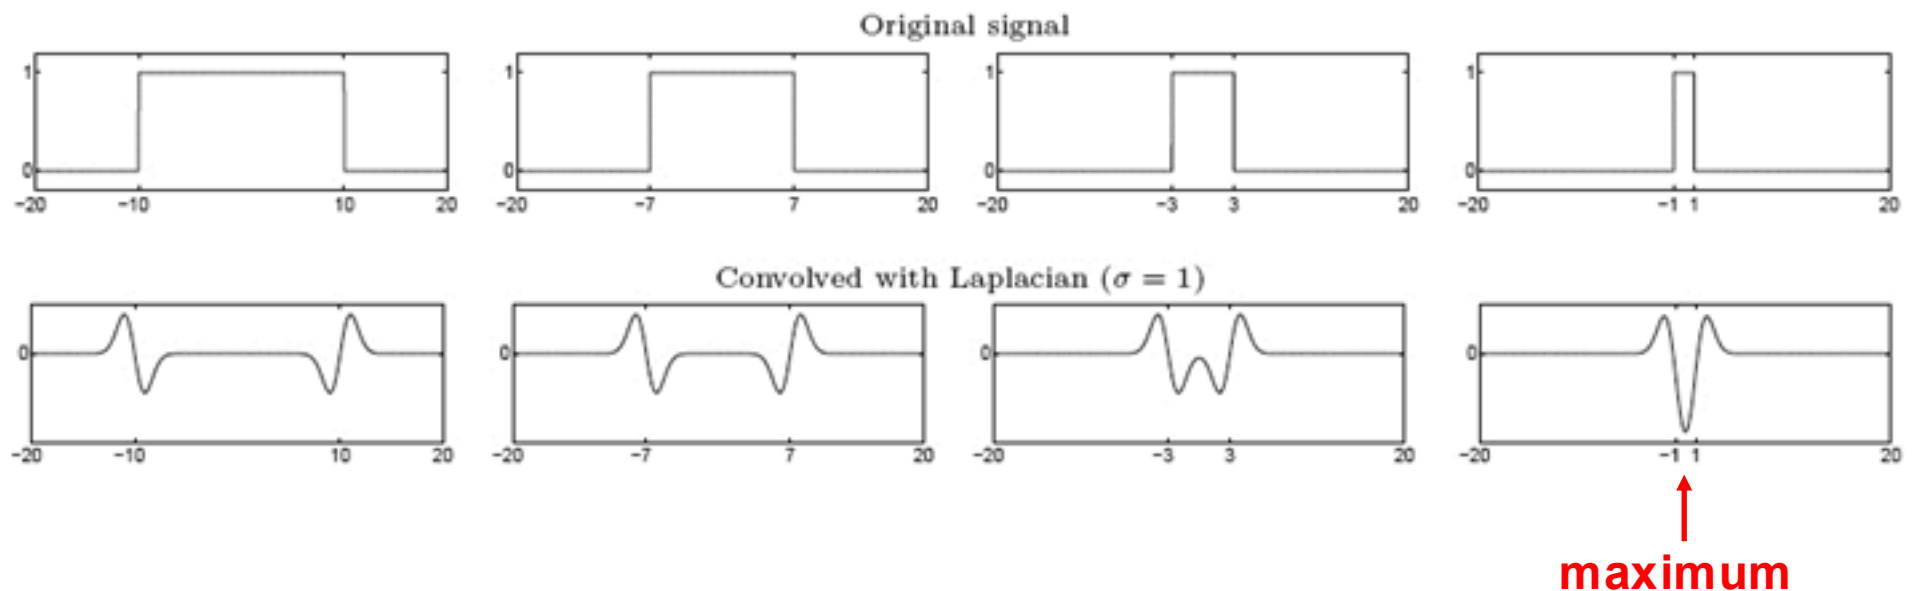


Край = переход
через ноль второй
производной



От краев к блобам

- Край = «всплеск»
- Блоб = совмещение двух «всплесков»




Выбор масштаба: величина отклика лапласиана Гауссиана достигает максимума в центре блоба в том случае, если размер лапласиана «соответствует» размеру блоба



Выбор масштаба

- Нужно найти характеристический размер блока путем свертки с Лапласианом в нескольких масштабах и найти максимальные отклики
- Однако, отклик Лапласиана затухает при увеличении масштаба:




Почему так происходит?



Нормализация масштаба

- Отклик производной фильтра Гаусса на идеальный край затухает с увеличением масштаба σ






Нормализация масштаба

- Отклик производной фильтра Гаусса на идеальный край затухает при увеличении σ
- Нужно домножить производную на σ для достижения инвариантности к масштабу
- Лапласиан это вторая производная фильтра гаусса, поэтому домножаем на σ^2








Эффект нормализации






Исходный сигнал



Ненормализованный отклик Лапласиана



Нормализованный по масштабу отклик Лапласиана





↑
максимум



Поиск блобов в 2D

Лапласиан Гауссиана: Центральнo-симметричный оператор поиска блобов в 2D





$$\nabla^2 g = \frac{\partial^2 g}{\partial x^2} + \frac{\partial^2 g}{\partial y^2}$$



Поиск блоков в 2D

Лапласиан Гауссиана: Центральнo-симметричный оператор поиска блоков в 2D




Нормализация:

$$\nabla_{\text{norm}}^2 g = \sigma^2 \left(\frac{\partial^2 g}{\partial x^2} + \frac{\partial^2 g}{\partial y^2} \right)$$




Выбор масштаба


- На каком масштабе Лапласиан достигает максимума отклика на бинарный круг радиуса r ?



изображение



Лапласиан






Выбор масштаба


- 2D Лапласиан задается формулой:

$$(x^2 + y^2 - 2\sigma^2) e^{-(x^2 + y^2)/2\sigma^2} \quad (\text{с точностью до масштаба})$$

- Для бинарного круга радиуса r , Лапласиан достигает максимума в $\sigma = r / \sqrt{2}$




изображение





Характеристический размер

- Характеристический размер определяется как масштаб, на котором достигается максимум отклика Лапласиана




Характеристический масштаб


T. Lindeberg (1998). ["Feature detection with automatic scale selection."](#)
International Journal of Computer Vision **30** (2): pp 77--116.



Характеристический размер




У «хорошего блоба»— один ярко выраженный пик функции





Многомасштабный детектор блоков

1. Свертываем изображение нормализованным фильтром Лапласиана на разных масштабах
2. Ищем максимум отклика Лапласиана в 3D





Пример






Пример



$\sigma = 11.9912$



Пример





Эффективная реализация (DoG)


Приближение Лапласиана с помощью разницы гауссиан:

$$L = \sigma^2 \left(G_{xx}(x, y, \sigma) + G_{yy}(x, y, \sigma) \right)$$

(Лапласиан)

$$DoG = G(x, y, k\sigma) - G(x, y, \sigma)$$


(Разница Гауссиан)



Difference of Gaussian = DoG



Эффективная реализация (DoG)




Детектор DoG также выделяет «блобы» на изображении

David G. Lowe. ["Distinctive image features from scale-invariant keypoints."](#)
IJCV 60 (2), pp. 91-110, 2004.



Детектор Harris-Laplacian

- Выделяем углы на изображении, но с характеристическим размером
- Максимизация:
 - По изображению – откликов углов Харриса
 - По масштабу – Лапласиана
- Разные варианты чередования вычисления функции Харриса и Лапласиана






Сравнение

- Сравнение простого детектора Харриса и Харрис-Лапласиана



Харрис



Харрис-Лаплас



Углы и блобы



- Углы и блобы – разные виды локальных особенностей
- Детекторы Харрис-Лапласиан и LoG (DoG) выделяют разные множества особенностей
- Можно применять их одновременно



Выбор точек

- Цель: выбрать фиксированное кол-во точек на изображении
 - Точки должны быть равномерно распределены по изображению
 - Самые сильные отклики обычно расположены в текстурированных областях, неравномерно распределенных по изображению



(a) Strongest 250




(b) Strongest 500



Адаптивный радиус

- Пройдёмся по всем точкам в порядке качества
- Для каждой точки выкинем из списка всех соседей в окрестности радиуса r
- Посчитаем количество оставшихся точек
- Выберем такой радиус r , при котором получим нужное нам количество точек





Детекторы областей


- Стоит попробовать работать с более уникальными характеристиками изображения – с областями
- Интересных областей гораздо меньше, но они более точно характеризуют сцену или объект



Детекторы областей

- Детектор областей IBR (Intensity-extrema based regions)
- Идти от локального экстремума яркости по лучам, считая некоторую величину f
- Остановка при достижении пика f


$$f(t) = \frac{|I(t) - I_0|}{\frac{1}{t} \int_0^t |I(t) - I_0| dt}$$





Детекторы областей


- Области на паре изображений могут различаться, поэтому опишем вокруг них эллипсы



- Если эллипсы превратить в окружности, то получим полное сходство с точностью до поворота (об этом позже)



Детекторы областей





Детекторы областей


MSER = Maximally Stable
Extremal Regions

- Задать порог яркости T
- Провести сегментацию
- Извлечь области
- Для каждой области найти порог, при котором рост площади минимален
- Описать вокруг области эллипс








Детекторы областей





Детекторы областей






Резюме локальных особенностей

- Локальные особенности – один из основных инструментов анализа изображений
- Рассмотрели алгоритмы выделения особенностей:
 - Уголки: Harris (Forstner), Harris-Laplace)
 - Блобы: LoG (Laplacian of Gaussian), DoG (Difference of Gaussians)
 - Области: IBR (Intensity-extrema based regions), MSER (Maximally Stable Extremal Regions)



Дескрипторы

Точки найдены – как их сопоставить?




- Нужно как-то описать каждую точку, чтобы можно было отличать одну от другой!
- Дескриптор (Descriptor) - вектор признаков окрестности точки



Дескрипторы

Необходимо каждую интересную точку описать набором параметров:




$$\mathbf{f}_n = (f_{n,1}, \dots, f_{n,j})^T$$

Как будем поступать:

- Возьмём окрестность точки
 - Какой формы?
 - Какого размера?
- Вычислим по окрестности набор признаков
 - Какие?



Простейший подход



- Возьмём квадратные окрестности, со сторонами, параллельными строкам и столбцам изображения
- Яркости пикселей будут признаками
- Сравнивать будем как изображения попиксельно (SAD, SSD)
- Такая окрестность инвариантна только к сдвигу изображения



Инвариантность к яркости

- Можем добиться следующим образом:
 - Локальная нормализация гистограммы
 - Дескрипторы, основанные на градиенте яркости, инвариантны к сдвигу яркости
 - Нормирование яркости - вычесть среднее значение, поделить на дисперсию

$$I' = (I - \mu) / \sigma$$




нормализация





Недостаток простой окрестности



- Детектор точек инвариантен к повороту, а окрестность нет
- Небольшие сдвиги, т.е. ошибки в нахождении точки делают невозможным попиксельное сравнение



SIFT


- Scale-Invariant Feature Transform:
 - Детектор DoG
 - Определение положения и масштаба особенности
 - Ориентация
 - Определение доминантной ориентации по градиентам
 - Deskриптор
 - Использование статистик по направлению градиентам
- Устойчив к изменениям освещенности и небольшим сдвигам

David G. Lowe. ["Distinctive image features from scale-invariant keypoints."](#) *IJCV* 60 (2), pp. 91-110, 2004.




Ориентация

- Идея: найти основное (доминантное) направление градиентов пикселей в окрестности точки
- Посчитаем гистограмму, взвешивая вклад по гауссиане с центром в точке



- Повернуть фрагмент так, чтобы доминантное направление градиента было направлено вверх



- Если локальных максимумов несколько – считаем, что несколько точек с разной ориентацией



Окрестность особенности



- Для каждой найденной особенности теперь знаем характеристические масштаб и ориентацию
- Выберем соответствующую прямоугольную окрестность
 - (Rotation Invariant Frame)
- Приведем окрестность к стандартному размеру (масштабируем)




Пример локальных особенностей






Гистограмма ориентаций градиентов



- Построим дескриптор SIFT – идея:
 - Вычислим направление градиента в каждом пикселе
 - Квантуем ориентации градиентов на 8 ячеек (направлений)
 - Понетим каждый пиксель номером ячейки
 - Посчитаем гистограмму направлений градиентов
 - Для каждой ячейки посчитаем количество пикселей с номером этой ячейки
 - Вклад взвесим по гауссине, с центром в центре окрестности



Гистограммы градиентов



- Для учета локальных свойств разделим окрестность на блоки сеткой, в каждом блоке посчитаем свою гистограмму градиентов
- Обычно – сетка 4x4, в каждой гистограмма с 8ю ячейками
- Стандартная длина вектора-дескриптора – 128 ($4 \times 4 \times 8$)
- Сравниваем как вектор (разные метрики)



Сравнение SIFT

- Вектор-признак длиной 128, по сути гистограмма
- Стандартные L1, L2
- Специальные для гистограмм:

- Пересечение гистограмм
$$D(h_1, h_2) = \sum_{i=1}^N \min(h_1(i), h_2(i))$$

- Расстояние χ^2
$$D(h_1, h_2) = \sum_{i=1}^N \frac{(h_1(i) - h_2(i))^2}{h_1(i) + h_2(i)}$$

- Earth-Mover Distance



Использование цвета

- RGB-SIFT

- 3 дескриптора SIFT для каждого канала

- C-SIFT

- Каналы O_1 и O_2

$$\begin{pmatrix} O_1 \\ O_2 \\ O_3 \end{pmatrix} = \begin{pmatrix} \frac{R-G}{\sqrt{2}} \\ \frac{R+G-2B}{\sqrt{6}} \\ \frac{R+G+B}{\sqrt{3}} \end{pmatrix}$$

- rgSIFT


- Каналы r и g

$$\begin{pmatrix} r \\ g \\ b \end{pmatrix} = \begin{pmatrix} \frac{R}{R+G+B} \\ \frac{G}{R+G+B} \\ \frac{B}{R+G+B} \end{pmatrix}$$




Резюме SIFT

- Детектор SIFT весьма специфичен, устойчив к изменениям освещения, небольшим сдвигам
- Вся схема SIFT (детектор, выбор окрестностей, дескриптор) оказалась очень эффективным инструментом для анализа изображений
- Очень широко используется





Перспективные искажения






Дескрипторы



В круглую окрестность попадают разные фрагменты – в левом снимке внутрь окружности попала половина буквы G, в правом он почти не попала




Дескрипторы



Найти соответствующие окрестности, с учетом аффинных преобразований описав их эллипсом



Нормализация окрестности



Для облегчения сравнения фрагментов изображения необходимо найти параметры эллипса вокруг интересной точки или области и привести эллипсы к «каноническому» виду – «общему знаменателю»




Аффинная адаптация

Помним:
$$M = \sum_{x,y} w(x,y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} = R^{-1} \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} R$$

Матрицу M можно представить как эллипс, у которого длины осей определены собственными значениями, а ориентация определена матрицей R


Уравнение эллипса:

$$\begin{bmatrix} u & v \end{bmatrix} M \begin{bmatrix} u \\ v \end{bmatrix} = \text{const}$$





Афинная адаптация




Проблема: мы матрицу M считаем по круглой (квадратной) окрестности. На разных изображениях содержимое будет не совпадать, и мы не сможем выделить одинаковые области (эллипсы)

Решение: итеративная адаптация




Аффинная адаптация

- Задача: матрица вторых моментов, определенная весами $w(x,y)$ должна вычисляться по характерной формой области
- Решение: итеративное уточнение
 - Считаем матрицу моментов по круглому окну
 - Применяем аффинную адаптацию для получения эллиптического окна
 - Пересчитываем матрицу моментов по нормализованной окрестности. Повторяем.






Пример аффинной адаптации



Независимые от масштаба области (блобы)



Пример аффинной адаптации




Уточненные окрестности блобов



Нормализация


- Эллипс вторых моментов можно считать «характеристической формой» области
- Нормализуем окрестности путем преобразования эллипса в единичный круг





Неопределенность ориентации

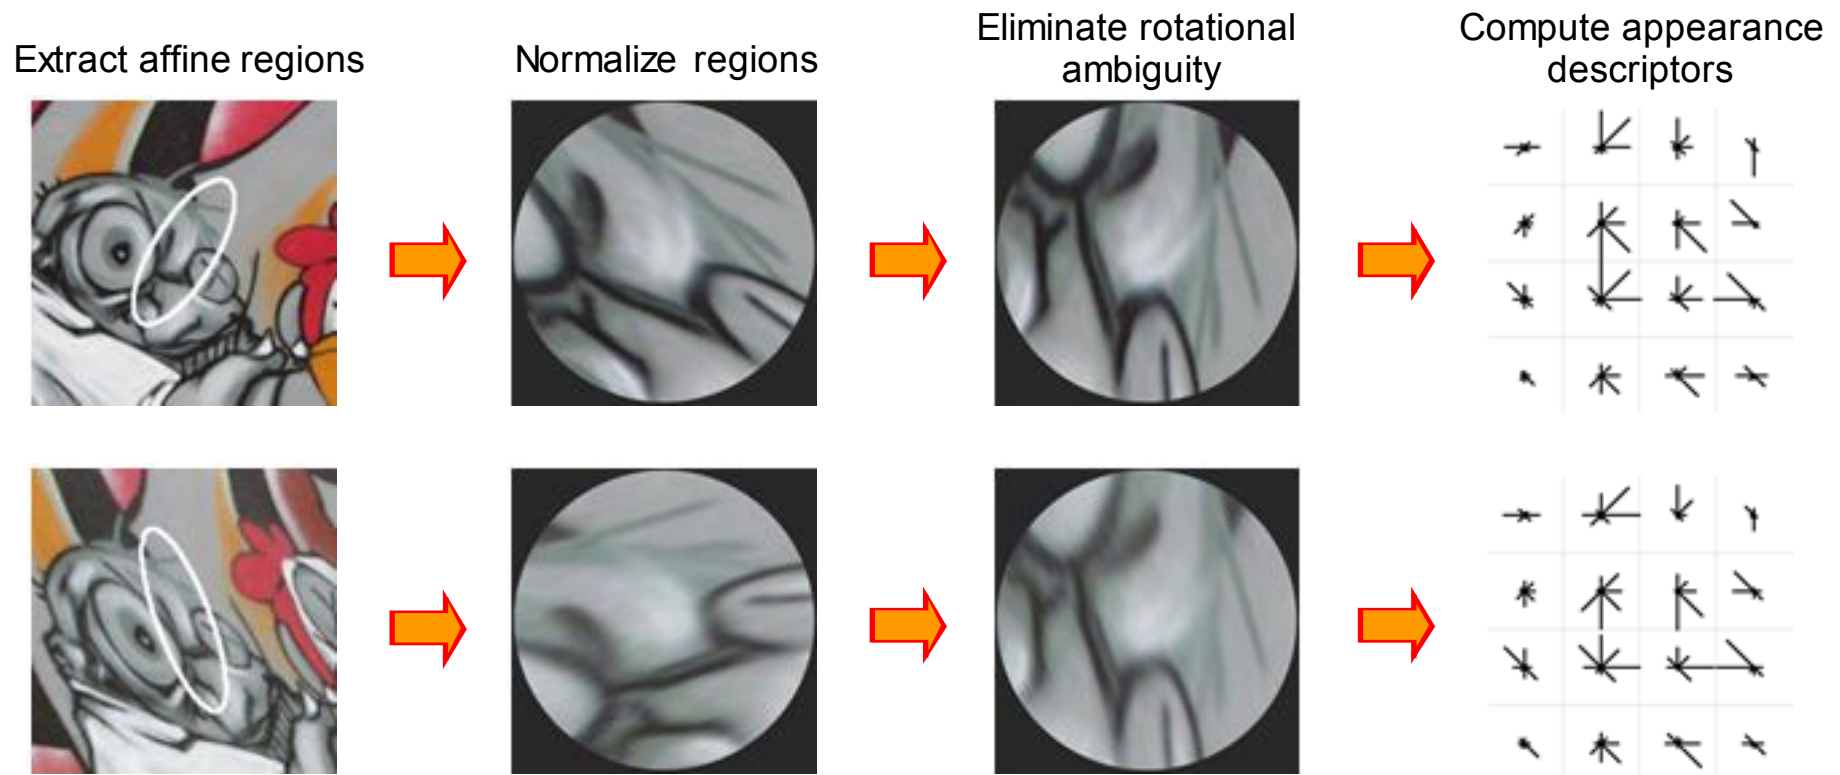
- Нет уникального преобразования из эллипса в единичный круг
 - Мы можем вращать и отражать единичный круг, и он останется единичным кругом



- Посчитаем доминирующий градиент и повернём!



Пример





K. Mikolajczyk and C. Schmid, [Scale and Affine invariant interest point detectors](#), IJCV 60(1):63-86, 2004.

<http://www.robots.ox.ac.uk/~vgg/research/affine/>



Сопоставление


- Имеем набор точек и дескрипторов
- Как будем сопоставлять?





Сопоставление особенностей

- Генерируем пары-кандидаты: для каждого патча в одном изображении, находим несколько наиболее похожих по выбранной метрике патчей на другом изображении
- Как выбирать пары?
 - Полный перебор
 - Для каждой особенности вычисляем расстояния до всех особенностей второго изображения и берем лучшую
 - Ускоренные приближенные меры
 - Иерархические структуры (kd-trees, vocabulary trees)
 - Хэширование





Резюме лекции

- Сопоставление изображений – одна из основных задач в компьютерном зрении
- Прямое сопоставление иногда работает, но страдает от ряда недостатков
- Локальные особенности – один из основных инструментов для анализа изображений
 - Детекторы: Harris, LoG, DoG, Harris-Laplace
 - Дескрипторы: SIFT, C-SIFT
 - Афинная адаптация



На следующей лекции

- Геометрические модели – прямые, окружности, преобразование изображений
- DLT-метод для оценки их параметров
- Робастные методы оценки параметров
 - Рандомизированные методы
 - Схемы голосования
- Выделение экземпляров объектов через сопоставление